

به نام خدا

علی سلیم خانی 401463141
پروژه نهایی درس ریانش عصبی

در این پروژه از معماری vision transformer برای تشخیص حواس پرتی رانندگان در حالات مختلف استفاده شده. مدل از پایه و scratch انجام شده و از مدل‌های آماده و transfer learning استفاده نشده است. در این پروژه تنها از دیتاست state farm distracted driver detection استفاده شده است.

2- با توجه به مجموعه داده‌ای آماده کردید، مراحل پیش پردازش داده ها را انجام داده و کلاسه‌ای خروجی را متناسب با هدف مورد نظر تعیین نمایید. همچنین بیان کنید این سامانه چه ویژگی هایی باید داشته باشد.

ابتدا تمام تصاویر را به اندازه 224×224 پیکسل تغییر می‌دهیم تا به عنوان ورودی با معماری مدل سازگار باشند. درواقع همه تصاویر را به زور در یک کادر جا می‌دهیم تا یک فرمت استاندارد برای ورودی مدل ایجاد شود. سپس از تکنیک های مختلف data augmentation برای جلوگیری از overfitting و قدرت تعمیم بهتر استفاده شده.

تکنیک های استفاده شده به تفصیل زیر میباشند:

RandomResizedCrop

این تکنیک تصویر را در مقیاس‌ها و نسبت‌های مختلفی تصادفی برش داده و سپس آن را به اندازه استاندارد تغییر اندازه می‌دهد. با این کار مدل یاد می‌گیرد که سوژه اصلی لزوماً همیشه در مرکز تصویر و یا اندازه ثابت نیست و دید منطقی پیدا می‌کند.



RandomHorizontalFlip

به صورت تصادفی تصاویر را به صورت افقی (چپ به راست) برعکس می‌کند تا مدل با زاویه‌های دید مختلف روبرو شود. این کار باعث می‌شود مدل برای تشخیص وابسته به سمت خاصی نباشد و تعمیم‌پذیری آن افزایش یابد.

RandAugment

مجموعه‌ای از تبدیلات هندسی و رنگی را به صورت خودکار و رندوم روی تصویر اعمال می‌کند. این کار تنوع داده‌های آموزشی را به بسیار بالا می‌برد و مدل را مجبور می‌کند تا ویژگی‌های واقعی را یاد بگیرد.




ColorJitter

پارامترهای رنگی تصویر شامل روشنایی، کنتراست، اشباع رنگ و رنگ‌پذیری را به طور تصادفی تغییر می‌دهد. این تغییرات مدل را در برابر تغییرات شرایط نوری (مثل آفتاب، سایه یا شب) مقاوم می‌کند تا وابسته به رنگ‌ها یا شرایط نوری ثابت نباشد.




RandomGrayscale

تصویر را با احتمال مشخصی به سیاه و سفید تبدیل می‌کند تا تمام اطلاعات رنگی حذف شود. با این کار مدل مجبور می‌شود به جای تکیه بر رنگ (مثلاً دلتا سبز راننده یا گوشی) توسط فرمان یا سایه پنهان شده باشد، همچنان بتواند درست تشخیص دهد.



RandomErasing

یک مستطیل تصادفی از تصویر را پاک کرده و آن را با رنگ ثابت یا نویز پر می‌کند تا مدل را آماده می‌کند تا در صورتی که بخشی از تصویر (مثلاً دست راننده یا گوشی) توسط فرمان یا سایه پنهان شده باشد، همچنان بتواند درست تشخیص دهد.



MixUp - CutOut - CutMix

این ها مجموعه تکنیک هایی هستند که دو تصویر را با هم ترکیب میکنند یا قسمتی از تصویر را حذف میکنند. تمام این اقدامات برای تعمیم پذیری هرچه بیشتر است



در مرحله بعد تصاویر را نرمال می‌کنیم و برای این کار از میانگین و انحراف معیار استاندارد ImageNet استفاده می‌کنیم. از این مقادیر در اکثر پروژه‌های بینایی ماشین استفاده می‌شود، چرا که مقادیر پیکسل‌ها را از بازه وسیع 0 تا 255 به بازه‌ای کوچک و استاندارد حول صفر (معمولاً بین -1 تا 1) تبدیل می‌کند. این کار مانع از انفجار یا محو شدن گرادیان می‌شود.

سپس تفکیک مبتنی بر Driver-Based Split) انجام می‌شود. در روش‌های معمول تقسیم داده random split تصاویر به صورت تصادفی بین آموزش و تست بخش می‌شوند. اما در این دیتاست این روش اشتباه است چون ممکن است 80% از تصاویر "علی" در آموزش و 20% باقی‌مانده در تست قرار بگیرد. در این صورت وقتی مدل در تست عکس علی را می‌بیند، چون چهره و لباس علی را می‌شناسد، پیش‌بینی می‌کند که او دارد تایپ می‌کند، بدون اینکه اصل به دستش نگاه کند. به این اتفاق data leakage گفته می‌شود. برای جلوگیری از این اتفاق، ما داده‌ها را بر اساس شناسه راننده جدا می‌کنیم. در این حالت ما تصمیم می‌گیریم که متناوباً راننده‌های A، B و C فقط در آموزش باشند. راننده‌های D و E هم فقط در اعتبارسنجی باشند.

این سامانه باید بتواند مستقل از مشخصات ظاهری راننده یا ماشین (رنگ لباس راننده، رنگ پوست، رنگ مو، نوع داشبورد یا فرمان و غیره) تمام حالات رانندگی را تشخیص دهد و همچنین تعمیم‌پذیری بالا داشته باشد و بتواند برای کسانی که تا به حال آن‌ها را ندیده نیز به خوبی عمل کند و تشخیص دهد. همچنین نباید زمان inference طولانی باشد و باید real-time باشد چرا که این سیستم safety critical است یعنی اگر این سیستم تأخیر داشته باشد یا از کار بیوفتد عواقب احتمالی ناگوار خواهند بود. پس شبکه نباید خیلی بزرگ باشد و باید تعداد پارامترها را در نظر داشته باشیم.

c0	"Safe Driving"
c1	"Texting - Right"
c2	"Talking - Right"
c3	"Texting - Left"
c4	"Talking - Left"
c5	"Operating Radio"
c6	"Drinking"
c7	"Reaching Behind"
c8	"Hair/Makeup"
c9	"Talking to Passenger"

3- ساختار Vision Transformer بر بررسی کرده و توضیح دهید چگونه میتوان از این ساختار برای این کار استفاده کرد.

ساختار Vision Transformer تصویر را مانند یک "متن" پردازش می‌کند. ابتدا تصویر ورودی را به قطعات کوچکی به نام (Patch) تقسیم می‌کنیم که هر کدام مثل یک کلمه در یک جمله عمل می‌کنند. سپس، چون مدل نمی‌تواند ترتیب اشیا را تشخیص دهد positional encoding را اضافه می‌کنیم تا مدل بداند هر بخش در کجای تصویر قرار دارد. در مرحله بعد این پچ‌ها وارد مکانیزم Self-Attention می‌شوند. این بخش اجازه می‌دهد هر پچ با تمام پچ‌های دیگر ارتباط برقرار کند. مثلاً برای تشخیص صحبت با تلفن، مدل می‌تواند مستقیماً رابطه بین پچ دست و پچ گوشی را بسنجد و متوجه شود که راننده در حال تایپ کردن است. در نهایت، یک توکن خاص به نام CLS اطلاعات کل تصویر را جمع‌آوری کرده و نتیجه نهایی را اعلام می‌کند.

4- مدل Vision Transformer خود را از ابتدا (بدون استفاده از مدلهای از پیش تعریف شده) بسازید و آن را آموزش دهید. برای آموزش، حداقل دو بهینه‌ساز مختلف را با هم مقایسه کنید و دلایل انتخاب پارامترهای آموزش را توضیح دهید. دقت کنید مدل به گونه‌ای باشد که به صورت بهینه (استفاده از منابع کمتر و سرعت بیشتر در مرحله ی استنتاج) اجرا شود و نتیجه ی مطلوبی داشته باشد.

با استفاده از پایتویچ توابع پیاده سازی شدند و آموزش از صفر آغاز شد و دو بهینه ساز AdamW و SGD با یکدیگر مقایسه شدند مشاهده شد که SGD برای آموزش ترنسفورمر را صفر بسیار کند عمل می‌کند و نیاز به تنظیمات پیچیده هاپیر پارمتر ها دارد در حالی که AdamW به دلیل مکانیزم تطبیقی نرخ یادگیری و Weight Decay همگرایی بسیار سریعتری داشت، بنابراین آن را انتخاب می‌کنیم.

برای اینکه مدل در مرحله استنتاج سریع‌تر بالایی داشته و منابع کمتری مصرف کند از معماری «ViT-Tiny» استفاده می‌کنیم یعنی Embed را 192 و عمق شبکه را 8 لایه در نظر می‌گیریم که باعث می‌شود تعداد پارامترها کم و مدل سبک باشد.

همچنین از 0.2 = dropout استفاده می‌کنیم تا از co-adaptation جلوگیری شود و همچنین Weight Decay = 0.1 این پارامتر مدل را به ازای ضرایب زیاد جریمه می‌کند که این کار باعث می‌شود مدل ساده‌تر بماند و روی داده‌های جدید بهتر عمل کند.

5- نتایج پیشبینی مدل را با استفاده از معیارهای مناسب گزارش دهید.


مدل چندین و چندباری را با حالت قبل مقایسه نمود. نتایج train شده در موارد ابتدایی چون تفکیک مبتنی بر راننده و تکنیک های دیناگمنتیشن مثل Mixup ، CutMix انجام نشده بود مدل به طرز عجیبی در 5 اپیک اول به دقت 70 درصد میرسید. اما زمانی که مدل را دانلود می‌کردیم در سیستم لوکال ران می‌کردیم و از پوشه test تصاویر را به مدل میدادیم. نتایج ناامید کننده بود و مشخص بود مشکلاتی وجود دارد (تصاویر پوشه test تصاویری هستند که در پوشه train وجود ندارند و برای مدل جدید هستند). پس از انجام اصلاحات مدل به طرز منطقی تری train شد و در اپیک 48 به دقت 60 درصد رسید. با این حال تعمیم پذیری مدل همچنان بسیار ضعیف است و از آنجایی که دسترسی به GPU رایگان در هر 3 اکانت چیمیل بنده تمام شد به این نتایج بسنده کردم.

با مشاهده attention map موارد درست تشخیص داده شده میتوان دریافت که مدل تا حد مقبولی نسبت به context اشراف دارد. اما تصاویر زیر تنها چند مورد درست بودند و موارد اشتباه بیشتر هستند.



6- بررسی کنید در چه مواردی مدل آموزش دیده شده نمی تواند پیشبینی درستی انجام دهد. همراه با مثال، علت را توضیح دهید.

بزرگترین مشکل مدل تعمیم پذیری آن است. یعنی نمیتواند روی افراد جدید به درستی عمل کند این بدان معناست که با تمام تمهیدات انجام شده هنوز data leakage رخ میدهد و مدل به جای یادگیری دست و تلفن و ... رنگ پوست و رنگ لباس و ... را یاد میگیرد.



برای مثال در این مورد attention map نشان میدهد که مدل به مکان اشتباهی توجه میکند و گویا گیج شده است. این اتفاق میتواند به این علت افتاده باشد که فرد در تصویر فردی سیاه پوست است.

7- (اختیاری) چگونه میتوان از Temporal Attention در این سامانه استفاده کرد؟ خروجی را با حالت قبل مقایسه کنید.

8- (اختیاری) خروجی میتوان سرعت مدل را در مرحلهی استنتاج افزایش داد؟ یکی از روشهای مؤثر را

یادبسناسازی و خروجی را با حالت قبل مقایسه نمایید.

یکی از مؤثرترین روش‌ها برای افزایش سرعت استنتاج تکنیک Dynamic Quantization است. در این روش، وزن‌های مدل که با دقت ۳۲ بیت (Float32) ذخیره شده‌اند به اعداد صحیح ۸ بیت (Int8) تبدیل می‌شوند. این کار حجم محاسبات را به شدت کاهش می‌دهد و سرعت پردازش را (به ویژه روی CPU) چند برابر می‌کند. از طرفی معمولاً افت دقت بسیار ناچیز است (حدود 1٪). در مدل هایی که دقت بالا است و وزن‌ها پایدار هستند، کاهش دقت در ازای افزایش چشمگیر سرعت قابل قبول است.

9- (اختیاری) چگونه میتوان از روش‌هایی مانند Federated Learning در این سامانه استفاده نمود؟

یادگیری فدرال یک روش توزیع‌شده برای آموزش مدل‌های یادگیری ماشین است. در این روش، به‌جای اینکه داده‌های خام به یک سرور مرکزی ارسال شوند، خود مدل به دستگاه‌هایی که داده تولید می‌کنند فرستاده می‌شود. در سامانه تشخیص حواس‌پرتی راننده، ابتدا یک مدل اولیه (مثلاً یک ViT کوچک) روی سرور مرکزی آماده می‌شود و وزن‌های آن برای خودروها ارسال می‌گردد. هر خودرو به‌جای ارسال تصاویر یا ویدئوها، فقط تغییرات محلی خودرو مثل تصاویر دوربین داخل کابین آموزش محلی، خودرو به‌جای ارسال تصاویر یا ویدئوها، فقط تغییرات وزن‌های مدل یا گرادیان‌ها را برای سرور می‌فرستد. سرور مرکزی این تغییرات را در همه خودروها جمع‌آوری کرده و با روشی مانند FedAvg آن‌ها را ترکیب می‌کند تا یک مدل به‌روزرشده بسازد. سپس نسخه جدید مدل دوباره برای همه خودروها ارسال می‌شود. مزیت این روش بالاتر رفتن هزینه به‌یشتن مدل در طی کار زمان است.